

Méthodes de constitution, d’OCR et d’audit d’un corpus numérique de traités diplomatiques

Mohammed-Karim Khaldi

Version méthodologique provisoire — 29 juin 2026

Résumé

Ce document décrit une méthode reproductible de transformation de fichiers PDF diplomatiques en une base textuelle exploitable pour la recherche documentaire et la constitution d’une base de connaissances. La chaîne privilégie la fidélité au document source, l’auditabilité page par page et la conservation des incertitudes. Elle combine extraction native PDF, OCR local par Apple Vision et Tesseract, sélection de candidats fondée sur des métriques de qualité, nettoyage déterministe, stockage d’état SQLite, export Markdown/JSONL, file de révision et versioning Git. Aucune correction générative ni reformulation automatique n’est appliquée au texte reconnu.

1 Statut du document

Ce texte est une version provisoire destinée à documenter la méthode pendant que le traitement OCR complet est encore en cours. Les valeurs numériques finales doivent être figées après génération définitive de `outputs_v2/manifest.json`.

Élément	Statut
Pipeline OCR	Implémenté localement dans <code>pdfkb</code>
État technique	<code>metadata/pipeline.sqlite3</code>
Version pipeline	2.0.1 au moment du brouillon
Sorties finales	À figer après fin OCR complète
Correction générative	Exclue

TABLE 1 – Statut méthodologique du document.

2 Objectif scientifique et documentaire

L’objectif est de produire, à partir d’un ensemble de PDF diplomatiques, une transcription textuelle fidèle, auditable et réutilisable. La finalité n’est pas d’obtenir un texte modernisé ou stylistiquement corrigé, mais une représentation documentaire contrôlable, page par page, permettant :

- la recherche plein texte ;
- l’indexation sémantique ;
- la constitution d’une base de connaissances ;
- la vérification humaine des pages incertaines ;
- la publication éventuelle d’un corpus documenté.

Deux couches textuelles sont distinguées. La couche brute conserve la transcription sélectionnée par page. La couche nettoyée applique uniquement des transformations déterministes destinées à améliorer la recherche et la segmentation documentaire. Les pages faibles ou incertaines ne sont pas supprimées ; elles sont incluses avec des drapeaux de révision.

3 Corpus source

Le corpus est constitué de fichiers PDF conservés localement dans le répertoire `traites/`. Chaque fichier correspond à un alias documentaire. Plusieurs alias peuvent renvoyer au même PDF physique lorsque leur empreinte SHA-256 est identique.

Les métadonnées initiales proviennent de `metadata/parsed_metadata.json`. Les champs disponibles incluent :

- `filename` : nom de fichier source ;
- `url` : URL documentaire source lorsqu'elle est disponible ;
- `treaty_id` : identifiant du traité ;
- `treaty_number` : numéro ou sous-référence documentaire ;
- `title` : titre documentaire ;
- `doc_type` : type documentaire normalisé ;
- `year` : année extraite ;
- `file_exists` : présence locale du fichier ;
- `file_size` : taille du fichier en octets.

3.1 Valeurs à compléter après traitement final

Indicateur	Valeur finale
Nombre d'alias documentaires PDF	À compléter
Nombre de PDF physiques uniques	À compléter
Nombre de pages logiques exportées	À compléter
Nombre de pages physiques uniques OCRisées	À compléter
Période chronologique couverte	À compléter
Nombre de pages sans erreur technique	À compléter
Nombre de pages nécessitant révision	À compléter

TABLE 2: Indicateurs à figer dans la version finale.

4 Inventaire et identification

Avant toute OCR, chaque PDF est inventorié. L'inventaire calcule :

- l'empreinte SHA-256 des octets du fichier ;
- le nombre de pages ;
- les dimensions et rotations PDF au niveau page ;
- le chemin local absolu ;
- le nom canonique associé à chaque SHA-256 ;

- les métadonnées documentaires associées au nom de fichier.

La distinction entre identifiant physique et identifiant documentaire est centrale. Le champ `source_sha256` identifie le PDF physique. Le champ `document_id` identifie l’alias documentaire lisible. Cette séparation permet de mutualiser le traitement des doublons exacts sans perdre les différents alias documentaires.

5 Unité de traitement

L’unité de traitement OCR est la page PDF physique, identifiée par :

- `source_sha256` ;
- `page_number`, numéroté à partir de 1 ;
- `pipeline_version`.

Le pipeline sauvegarde l’état après chaque page dans SQLite. Une page déjà transcrite avec succès ne peut pas être remplacée par un échec ultérieur. Les erreurs sont enregistrées séparément.

6 Extraction native PDF

Pour chaque page, le pipeline commence par extraire la couche texte native avec PyMuPDF. Cette extraction produit :

- le texte natif trié ;
- les blocs natifs ;
- les coordonnées normalisées des blocs ;
- la couverture approximative des images dans la page.

La couche native est utilisée seulement si elle est crédible. Les critères de crédibilité sont :

- au moins trois caractères ;
- absence de caractère de remplacement Unicode `U+FFFD` ;
- absence de caractère Unicode en zone privée ;
- ratio de caractères imprimables supérieur ou égal à 0,98 ;
- ratio de bruit inférieur ou égal à 0,01 ;
- score candidat supérieur ou égal à 0,82.

Si la couche native est crédible et que la couverture image est inférieure à 0,50, la page est considérée comme purement numérique et le raster OCR est évité.

7 Rendu image et mesure visuelle

Les pages nécessitant OCR sont rendues en image RGB à 300 DPI. Une mesure visuelle simple, `ink_ratio`, estime la proportion de pixels sombres sur une version réduite de l’image. Cette mesure sert notamment à détecter les pages visuellement non vides pour lesquelles aucun texte n’est reconnu.

Tesseract OSD est utilisé pour détecter l’orientation et le script lorsqu’il est disponible. Une rotation globale de 90, 180 ou 270 degrés peut être appliquée si la confiance d’orientation est suffisante.

8 Moteurs OCR

8.1 Apple Vision

Apple Vision est utilisé comme moteur OCR local principal pour les pages rasterisées. Il produit un candidat contenant :

- le texte reconnu ;
- des blocs textuels ;
- des coordonnées normalisées ;
- une confiance ;
- une variante de traitement, par exemple `original` ou `enhanced`.

8.2 Tesseract

Tesseract est utilisé comme moteur secondaire. Le choix du modèle dépend du script détecté par Apple Vision ou par OSD. Le mapping principal est le suivant :

Script détecté	Modèle Tesseract
Latin	<code>script/Latin</code>
Cyrillique	<code>script/Cyrillic</code>
Arabe	<code>script/Arabic</code>
Han	<code>script/HanS</code>
Japonais	<code>script/Japanese</code>
Hangul	<code>script/Hangul</code>
Grec	<code>script/Greek</code>
Hébreu	<code>script/Hebrew</code>
Devanagari	<code>script/Devanagari</code>
Thaï	<code>script/Thai</code>
Fraktur	<code>script/Fraktur</code>

TABLE 3: Modèles Tesseract par script.

Pour les pages latines datées avant 1950, le modèle complémentaire `fra+frm+lat+eng` est ajouté afin de couvrir le français moderne, le français ancien, le latin et l'anglais. Tesseract est lancé avec OEM 3, PSM 3 par défaut, et PSM 6 comme repli lorsque PSM 3 ne produit aucun texte exploitable.

9 Prétraitement visuel conservateur

Une variante améliorée de l'image peut être testée si le meilleur résultat initial est insuffisant ou si Tesseract ne produit aucun texte. Cette variante applique :

- conversion en niveaux de gris ;
- autocontraste léger ;
- augmentation de contraste limitée ;
- estimation d'un angle par les composantes sombres ;
- redressement uniquement lorsque l'angle est faible et plausible.

La binarisation agressive systématique est évitée. Le but est de préserver la morphologie documentaire des pages historiques.

10 Score de qualité des candidats

Chaque candidat OCR reçoit un score composite entre 0 et 1. La formule est :

$$S = 0.36 \cdot C + 0.20 \cdot P + 0.14 \cdot A + 0.14 \cdot T + 0.10 \cdot N + 0.06 \cdot E - \Pi \quad (1)$$

où :

- C est la confiance moteur ;
- P est le ratio de caractères imprimables ;
- A est un score lié au ratio alphanumérique ;
- T est un score pénalisant les mots isolés ;
- N est un score pénalisant les caractères de bruit ;
- E est une mesure logarithmique d'évidence textuelle ;
- Π est la pénalité pour caractères de remplacement et caractères Unicode en zone privée.

Le score final est borné entre 0 et 1. Il ne mesure pas la vérité documentaire, mais une qualité relative de transcription.

11 Accord inter-moteurs

Lorsque Apple Vision et Tesseract produisent tous deux un texte suffisant, un score d'accord est calculé. Les textes sont normalisés en Unicode NFKC, convertis en casse repliée, puis réduits aux seuls caractères alphanumériques. Une similarité de séquence est ensuite calculée.

Si les textes sont très longs, le début et la fin sont échantillonnés afin de limiter le coût de comparaison. Un accord supérieur à 0,55 peut accorder un faible bonus aux candidats Apple Vision et Tesseract. Un désaccord marqué peut déclencher une révision.

12 Sélection du meilleur candidat

La sélection ne dépend jamais uniquement du nombre de caractères. Elle suit les règles suivantes :

1. exclure les candidats vides si des candidats non vides existent ;
2. recalculer les scores de tous les candidats ;
3. retenir prioritairement la couche native lorsqu'elle est crédible ;
4. comparer Apple Vision et Tesseract lorsqu'ils sont disponibles ;
5. sélectionner le candidat au score final le plus élevé.

Les candidats non sélectionnés sont conservés dans l'audit complet.

13 Détection des langues et scripts

Les scripts sont détectés par plages Unicode. Les scripts reconnus incluent notamment latin, arabe, cyrillique, grec, hébreu, han, japonais, hangul, devanagari, thaï et lao. Les langues sont estimées sur un échantillon textuel normalisé.

Ces étiquettes sont descriptives et doivent être interprétées prudemment, notamment pour les pages courtes, multilingues ou très bruitées.

14 Nettoyage déterministe

Le nettoyage est appliqué uniquement à la couche destinée à la recherche et à l'indexation. Il comprend :

- normalisation Unicode NFC ;
- normalisation des espaces ;
- suppression de marqueurs invisibles ou de césure douce ;
- fusion conservatrice de lignes en paragraphes ;
- suppression des lignes marginales récurrentes en début ou fin de page.

La couche brute reste intacte. Les lignes retirées de la couche nettoyée sont conservées dans l'audit.

15 Règles de révision

Une page est signalée pour révision lorsqu'au moins une condition d'incertitude est satisfaite.

Raison	Définition
<code>low_confidence</code>	Score inférieur à 0,85.
<code>engine_disagreement</code>	Désaccord significatif entre Apple Vision et Tesseract.
<code>no_text_on_nonblank_page</code>	Page visuellement non vide avec texte quasi absent.
<code>sparse_extraction</code>	Page encrée mais extraction courte et incertaine.
<code>high_noise</code>	Ratio de bruit supérieur au seuil.
<code>mixed_scripts</code>	Trois scripts ou plus détectés.
<code>possible_handwriting_or_historical_document</code>	Document ancien avec désaccord moteur.

TABLE 4: Raisons de révision.

Les priorités sont définies ainsi :

Score ou condition	Priorité	Interprétation
$S \geq 0.85$, sans drapeau	none	Pas de révision requise
$0.65 \leq S < 0.85$ ou autre drapeau	normal	Révision recommandée
$S < 0.65$ ou page non vide sans texte	high	Révision prioritaire

TABLE 5: Priorités de révision.

16 Exports

Les sorties finales sont organisées comme suit :

Chemin	Contenu
<code>outputs_v2/raw/*.md</code>	Transcription brute sélectionnée, page par page.
<code>outputs_v2/clean/*.md</code>	Texte normalisé pour recherche.
<code>outputs_v2/kb/pages.jsonl</code>	Un enregistrement par page pour ingestion KB.

<code>outputs_v2/audit/pages.jsonl</code>	Audit détaillé : candidats, blocs, coordonnées, transformations.
<code>outputs_v2/review_queue.csv</code>	File des pages à contrôler.
<code>outputs_v2/manifest.json</code>	Comptes des documents, pages, erreurs et révisions.

TABLE 6: Livrables principaux.

Pendant le traitement, des snapshots légers peuvent être exportés vers `outputs_live/`. Ces snapshots excluent l’audit détaillé lourd mais conservent les Markdown, les pages JSONL pour la KB, la file de révision et le manifeste.

17 Métadonnées et tags

Le modèle de métadonnées distingue plusieurs niveaux :

- document ;
- page ;
- chunk de base de connaissances ;
- événement de révision ;
- tags contrôlés.

Les tags suivent le format `namespace:value`. Les namespaces recommandés incluent :

- `corpus` ;
- `stage` ;
- `doc_type` ;
- `period` ;
- `century` ;
- `language` ;
- `script` ;
- `ocr_method` ;
- `quality` ;
- `review` ;
- `review_reason` ;
- `rights_status`.

18 Versioning et audit externe

Les snapshots publiables sont conservés dans un dépôt Git séparé, `kb_repository/`. Ce dépôt permet :

- l’historique des changements ;
- l’inspection des diffs Markdown et JSONL ;
- la publication ultérieure via Forgejo ;
- la séparation entre traitement OCR actif et corpus publié.

Forgejo peut être utilisé comme interface web locale pour consulter les commits, les fichiers Markdown, les diffs et les versions publiées.

19 Validation

La validation repose sur :

- tests unitaires du scoring, du nettoyage et de l'état SQLite;
- benchmark stratifié incluant couche native, imprimé moderne, cyrillique, chinois, page presque vide et manuscrit historique;
- contrôle des comptes finaux;
- inspection de la file de révision;
- comparaison avec les sorties antérieures **extracted/**.

Les indicateurs finaux à publier comprennent :

- distribution des méthodes OCR;
- distribution des langues détectées;
- distribution des scripts;
- nombre et proportion de pages à réviser;
- nombre de pages prioritaires;
- erreurs techniques;
- exemples de pages acceptées, incertaines et prioritaires.

20 Reproductibilité

Une reproduction minimale nécessite :

1. les PDF sources ou leurs URLs;
2. `metadata/parsed_metadata.json`;
3. le code source du pipeline `pdfkb`;
4. les versions des moteurs OCR locaux;
5. la commande d'exécution;
6. le fichier d'état `metadata/pipeline.sqlite3` ou les exports JSONL;
7. le manifeste final;
8. les cas de benchmark.

La commande canonique est :

```
python -m pdfkb run \  
--source traitez \  
--metadata metadata/parsed_metadata.json \  
--output outputs_v2 \  
--state metadata/pipeline.sqlite3 \  
--workers 4 \  
--dpi 300 \  
--resume
```

21 Limites

Le score OCR ne constitue pas une mesure absolue de vérité documentaire. Les manuscrits, les pages très dégradées, les imprimés historiques, les documents multilingues et les pages très courtes peuvent rester incertains. La détection de langue peut être instable sur des segments courts ou bruités.

Les droits de publication ne sont pas inférés automatiquement. Ils doivent être établis par une analyse indépendante des conditions de diffusion des documents sources.

La méthode privilégie l'inclusion signalée plutôt que l'exclusion : les pages faibles sont conservées dans les sorties avec leurs drapeaux de révision.

22 Annexe : champs principaux

Champ	Niveau	Définition
<code>document_id</code>	document/page	Identifiant lisible dérivé du nom de fichier.
<code>source_sha256</code>	document/page	SHA-256 du PDF physique.
<code>source_filename</code>	document/page	Nom du fichier source.
<code>canonical_filename</code>	document/page	Nom canonique pour les doublons exacts.
<code>page_number</code>	page	Numéro de page, base 1.
<code>method</code>	page	Méthode OCR sélectionnée.
<code>quality_score</code>	page	Score composite entre 0 et 1.
<code>review_required</code>	page	Indique si la page nécessite une révision.
<code>review_reasons</code>	page	Raisons contrôlées de révision.
<code>text</code>	page/chunk	Texte destiné à la KB.
<code>pipeline_version</code>	tous	Version du pipeline producteur.

TABLE 7: Champs principaux du corpus publié.